OBIETTIVO DI RICERCA

Con l'avvento della tecnologia e delle innovazioni del design e nell'ingegneria automobilistica l'interesse per le prestazioni, l'affidabilità e l'efficienza dei veicoli sono aumentati in modo significativo.
In questo contesto l'analisi statistica dei dati può fornire preziose informazioni per comprendere meglio le preferenze dei consumatori, le tendenze di mercato e l'impatto di fattori come la potenza del motore e l'efficienza del carburante sul prezzo.

Le nostre teorie:

1. Il prezzo delle auto è influenzato dalla potenza del motore;
2. Il prezzo delle auto è influenzato positivamente dalla popolarità del modello;
3. C'è una relazione tra la grandezza dell'auto e il prezzo;
4. Le auto degli ultimi 5 anni costano di più (trend prezzo delle auto rispetto agli anni).

L'obiettivo finale di questa ricerca è quello di fornire informazioni utili e insight pratici per produttori, rivenditori e altri attori del settore automobilistico al fine di supportare processi decisionali informati e sviluppare prodotti che rispondano in modo efficace alle esigenze e alle preferenze dei consumatori moderni.

IL DATASET

I dati utilizzati provengono dal dataset "Car Features and MSRP" di Kaggle[1], il quale descrive quasi 12 mila auto vendute negli USA tra il 1990 e il 2017.
Le informazioni sono state estratte e verificate in modo accurato per garantire l'affidabilità dei dati raccolti. In caso di discrepanze o dati mancanti, sono state adottate procedure appropriate per la risoluzione del problema, inclusa la consultazione di fonti aggiuntive e l'aggiustamento dei dati se necessario.
Il dataset contiene le seguenti colonne:
<u>MAKE</u> = marchio dell'auto;
<u>CAR MODEL</u> = modello dell'auto;
<u>YEAR</u> = anno di immatricolazione dell'auto;
<u>ENGINE FUEL TYPE</u> = tipo di carburante che si divide in 8 tipologie:

1. Premium unleaded (required) → carburante senza piombo premium richiesto.
2. Premium unleaded (recommended) → carburante senza piombo premium raccomandato
3. Flex-fuel (unleaded/E85) → E85 è un'abbreviazione che in genere si riferisce a una miscela di carburante a base di etanolo e benzina.
4. Regular unleaded → benzina normale senza piombo
5. Diesel → Gasolio

[1] https://www.kaggle.com/datasets/CooperUnion/cardataset

6. Flex-fuel (premium unleaded recommended/E85) → sia carburante senza piombo sia E85
7. Electric → Elettrica
8. Natural gas → Metano
9. Flex-fuel (premium unleaded required/E85) sia carburante senza piombo premium sia E/85

ENGINE HP = potenza del motore in cavallo motore britannico (HP) che equivale a circa 1,014 cavallo vapore europeo (CV)
ENGINE CYLINDERS= Il numero dei cilindri
TRANSMISSION TYPE= tipo di trasmissione, se automatico, semiautomatico o manuale
DRIVEN_WHEELS= Ruote motrici, che possono essere **Rear-wheel drive** (trazione posteriore), **All wheel drive** (trazione 4x4 - la ripartizione della coppia motrice di un veicolo a motore su tutte le ruote di cui è dotato), **front wheel drive** (trazione anteriore), **four wheel drive** (4 ruote motrici o tutte le ruote motrici).
NUMBER OF DOORS= numero di portiere che va da 2 a 4.
MARKET CATEGORY= va a definire le categorie delle automobili.
VEHICLE SIZE= indica le dimensioni dell'automobile 'large', 'compact' e 'middle size'
VEHICLE TYPE= indica invece il tipo di veicolo, se è una "Coupe", "Convertible", "Sedan","4dr Hatchback", "Wagon", "2dr Hatchback", "4dr SUV", "Passenger Minivan", "Cargo Minivan", "rew Cab Pickup", "Regular Cab Pickup", "Extended Cab Pickup", "2dr SUV", "Cargo Van", "Convertible SUV", "Passenger Van"
HIGHWAY.MPG = miglia percorse in autostrada per un gallone di carburante (1 mpg = 0,4251 km al lt).
CITY.MPG = indica il consumo medio, sempre in miglia per galloni, in un circuito cittadino.
POPULARITY = indica il numero di interazioni sui social che coinvolgono il modello di auto
MSRP = (Manufacturer's Suggested Retail Price) è il prezzo di vendita al dettaglio suggerito.

ANALISI ESPLORATIVA

Prima di indagare le relazioni esistenti tra prezzo e altre caratteristiche delle auto è necessario effettuare tutte le operazioni di pulizia sul dataset.
Per prima cosa sono stati rimossi gli outliers delle variabili MSRP e Highway.mpg:

1. Per MSRP sono stati considerati i valori compresi tra i 2.000$ e i 300.000$;
2. Per Highway.mpg sono stati rimossi i valori superiori a 300.

Inoltre, sono stati rimosse le osservazioni con valori mancanti e i duplicati.

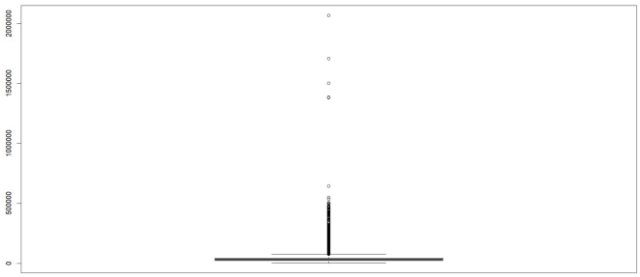

BOX PLOT PRIMA DI RIMUOVERE OUTLIERS SU MSRP

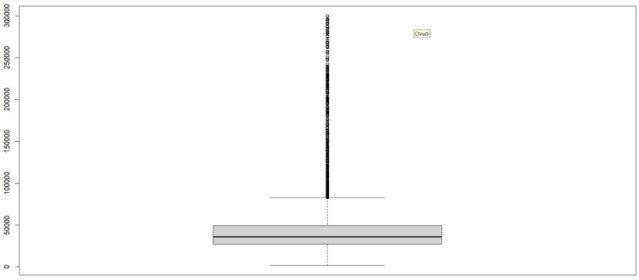

BOX PLOT MSRP DOPO AVER RIMOSSO GLI OUTLIERS

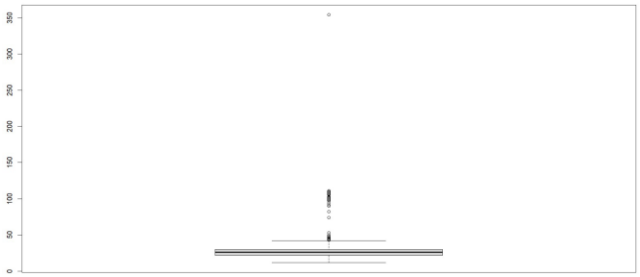

Box plot prima di rimuovere gli outliers su highway.mpg

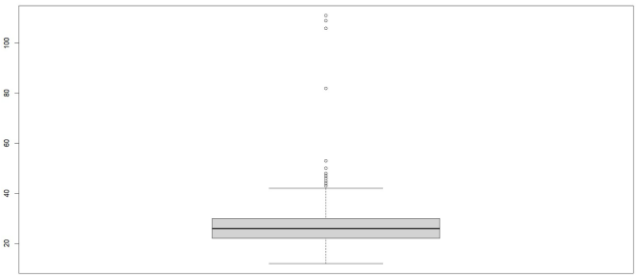

Box plot dopo aver rimosso gli outliers

Per quanto riguarda la variabile engine.fuel.type sono state raggruppate tutte le auto a benzina, senza fare distinzione tra l'uso raccomandato e l'uso obbligatorio di particolari tipologie di benzina.

```
  diesel electric unleaded
     146       13     7173
```

Successivamente è stata adottata la stessa logica di raggruppamento per la variabile Trasmission.type e Driven.Wheel:

- Per Trasmission.type sono state considerate le categorie "Manual", "Automatic" e "Automated_Manual"
- Per Driven.Wheel sono state considerate le categorie "All wheel drive"," Front wheel drive" e" Rear wheel drive"

```
AUTOMATED_MANUAL        AUTOMATIC           MANUAL
             523             5463             1346

all wheel drive front wheel drive  rear wheel drive
           2693               2426               2213
```

Considerando la variabile Market.category, si è deciso di eseguire un'operazione di split al fine di separare le diverse categorie in più colonne in modo tale da permettere il raggruppamento in un dizionario. In questo modo è possibile verificare quale categoria è maggiormente diffusa nel dataset.

Factory.Tuner	Luxury	High.Performance	Performance	Flex.Fuel	Hatchback	Hybrid	Diesel	Exotic	Crossover
585	2994	1301	1823	1173	900	333	198	377	1986

Effettuata una prima pulizia dei dati, sono state analizzate le correlazioni tra le variabili.

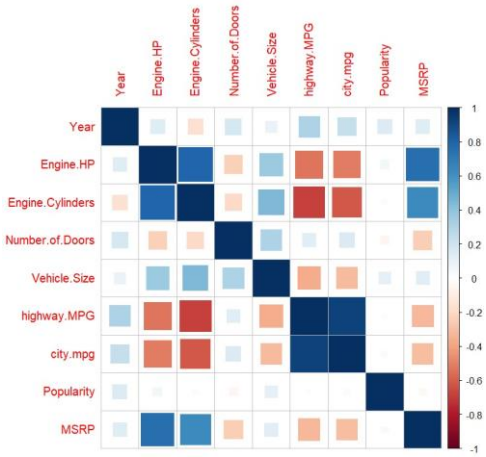

Da come si può notare, c'è una forte correlazione tra il numero di cavalli e il numero di cilindri. Tale correlazione positiva è dovuta dal fatto che un motore più potente, e quindi anche più grande, avrà bisogno di più cilindri e maggior numero di cavalli.
Altra correlazione positiva è quella tra la potenza del motore (Engine.HP e Engine.Ciliders) e il prezzo consigliato (MSRP) proprio perché per avere alte prestazioni il motore richiede più componenti e quindi un costo maggiore da sostenere per il produttore.
Le correlazioni negative riguardano, invece, la potenza del motore e le miglia percorse per singolo gallone di carburante.
Inoltre, è fin da subito possibile notare che vi è una bassa influenza della variabile "Popularity" e "MSRP".

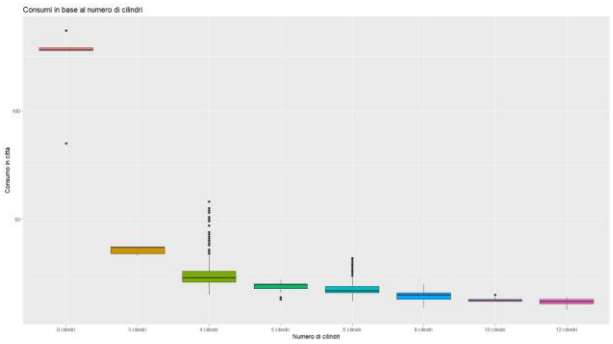

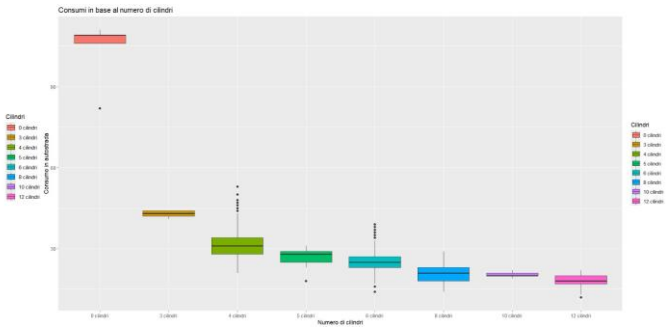

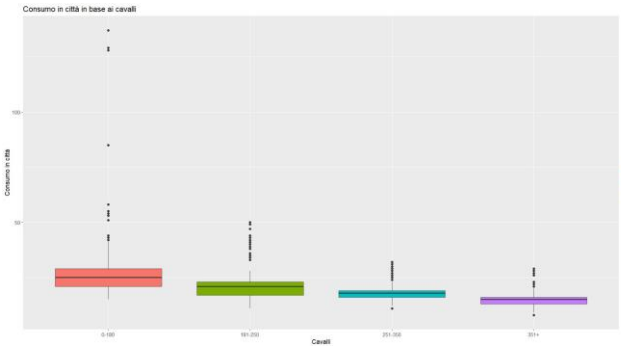

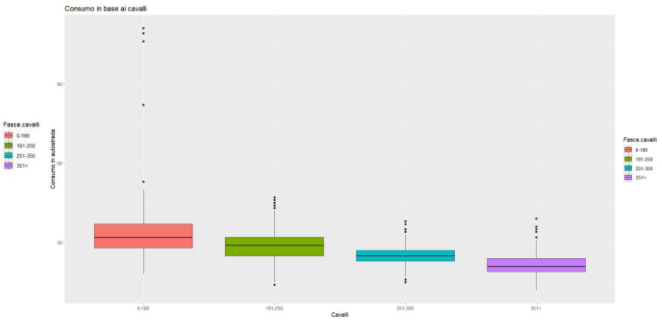

Affinchè l'auto sia più potente è necessario avere un auto di dimensioni maggiori. Di conseguenza, il prezzo aumenta in base alla grandezza dell'auto.

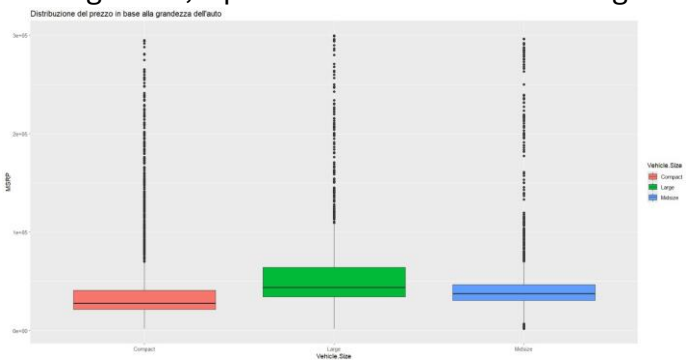

Al fine di avere un quadro completo della distribuzione delle vendite abbiamo analizzato le vendite nel corso del tempo, sia da un punto di vista quantitativo sia tenendo conto del prezzo medio delle auto nel corso degli anni

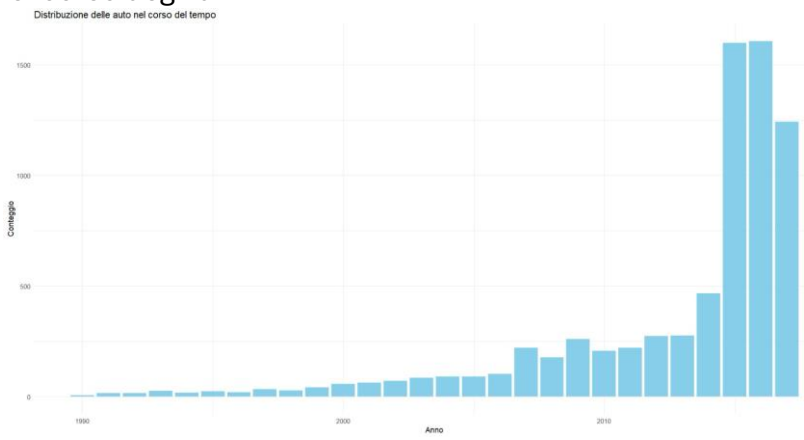

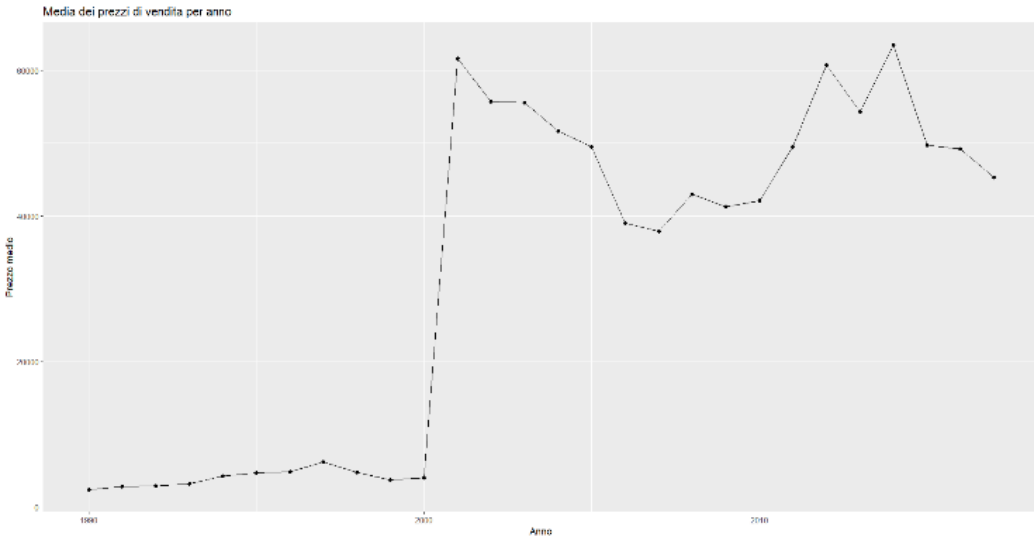

Dato che i dati sono relativi ad un rivenditore di auto sportive e di lusso, tra le categorie maggiormente diffuse abbiamo “Luxury”, “Performance”, “High.Performance” e “Crossover”

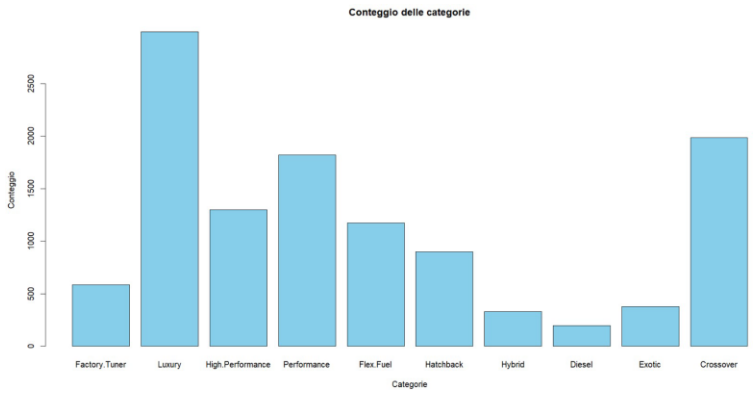

Inoltre, le tipologie di carrozzerie più diffuse sono suv, coupé e berline.

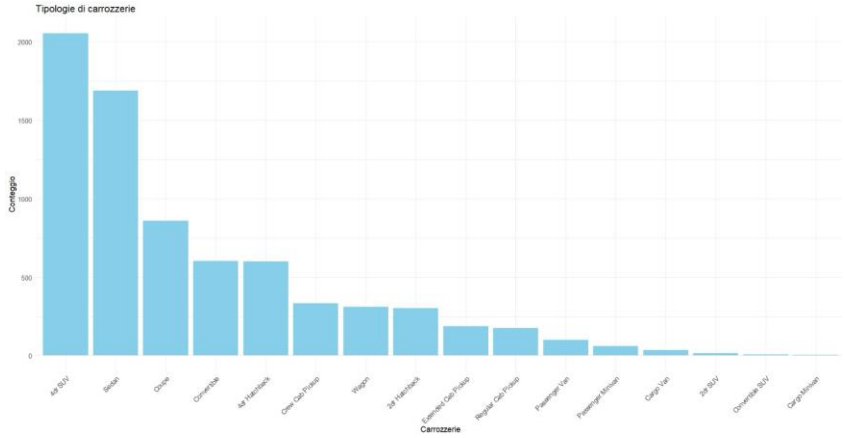

Ulteriori informazioni possono essere estratte tramite l’utilizzo della principal component analysis. Infatti, come si può vedere dalla matrice di correlazione alcune variabili sono ben correlate fra di loro.

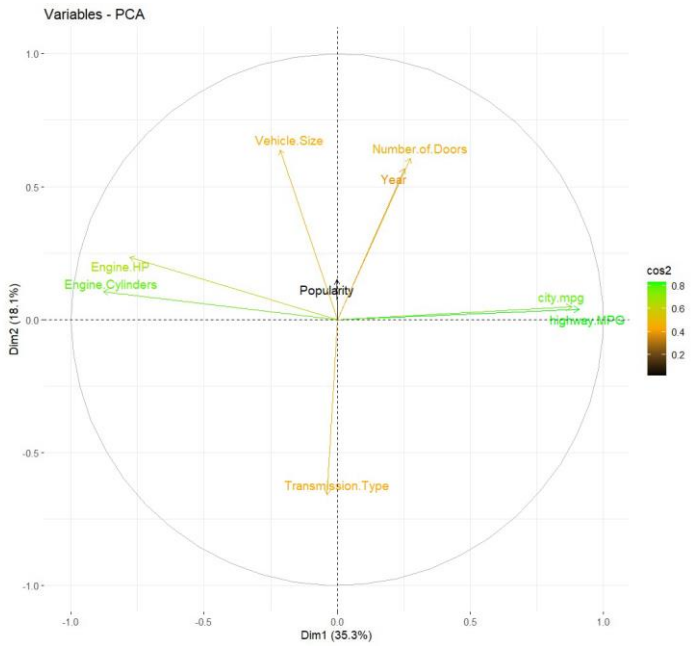

Come è possibile osservare dal grafico, tutte le variabili danno un buon contributo nel computo delle componenti principali, ad eccezione di popularity. Inoltre, come previsto la potenza del motore e i consumi si muovono in maniera opposta.
Prendendo in considerazione le prime 3 componenti principali, rappresentative del 67% della varianza, è possibile effettuare una prima classificazione delle auto suddividendole in fasce di prezzo.
La prima componente è stata interpretata come **l'efficienza del carburante** perché, tenendo conto dei loadings, i cavalli e i cilindri diminuiscono all'aumentare dell'efficienza del carburante. Inoltre, macchine più leggere ma con la stessa capacità di carico (inteso come posti a sedere) sono ritenute più efficienti. Infine, auto più nuove avranno una classe di emissione più alta.
La seconda componente è stata interpretata come **comfort** in quanto auto più nuove, più voluminose e con più porte sono più confortevoli. Auto con una maggiore potenza e con cambio automatico rendono l'esperienza di guida più confortevole.
La terza componente è stata interpretata come **novità e sportività**. Quindi, diminuendo il numero di porte e la dimensione della vettura abbiamo auto più sportive. La sportività è inoltre connessa alle prestazioni del motore, mentre, la novità è data dal fatto che con l'innovazione tecnologica degli ultimi anni, abbiamo auto più efficienti rispetto agli anni passati sia a parità di potenza che a parità di miglia percorse.
Le prime tre componenti hanno i seguenti pesi:

Loadings:

	Comp.1	Comp.2	Comp.3
Year	0.142	0.446	0.470
Engine.HP	-0.438	0.184	0.322
Engine.Cylinders	-0.493		0.111
Transmission.Type		-0.517	
Number.of.Doors	0.154	0.476	-0.426
Vehicle.Size	-0.120	0.501	-0.290
highway.MPG	0.511		0.173
city.mpg	0.495		0.147
Popularity		0.118	0.588

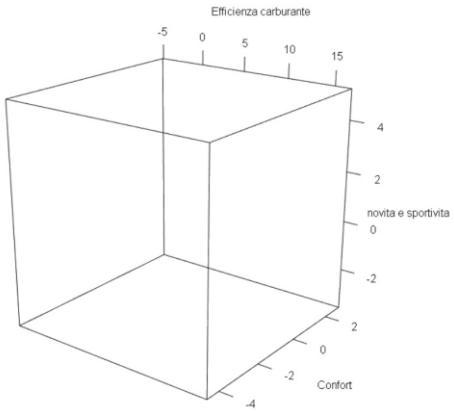

La suddivisione in fasce di prezzo è stata fatta tenendo conto delle informazioni trovate online guardando al mercato americano. Le fasce di prezzo sono le seguenti:

- Economy: 0-14.999$;
- Regular: 15.000$ - 29.999$;
- Premium: 30.000$ - 49.999$
- Luxury: +50.000$

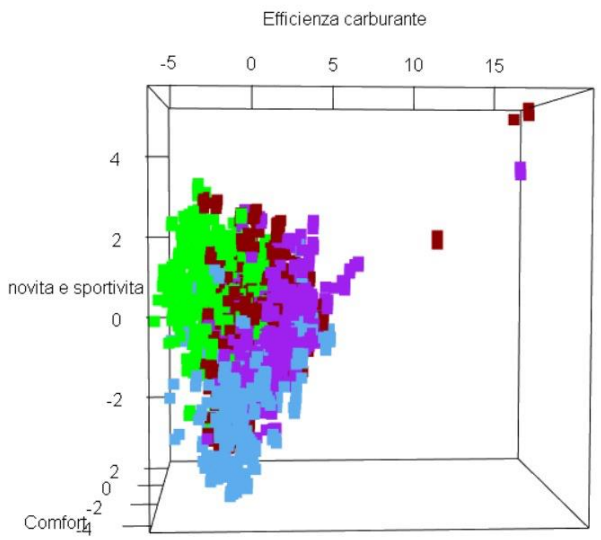

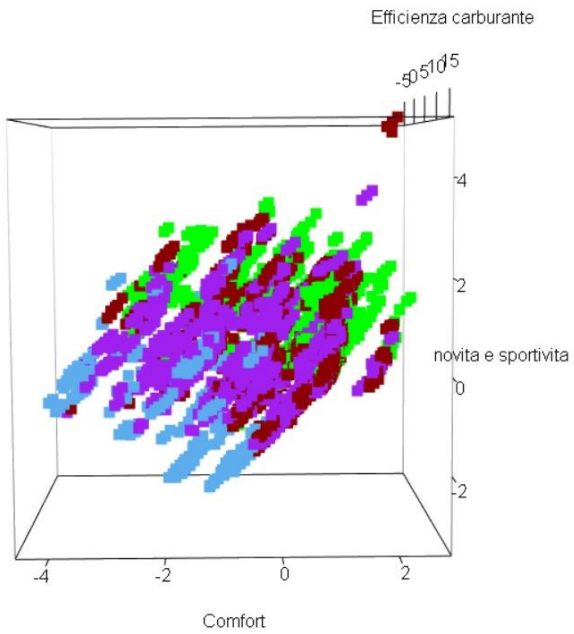

Nei grafici riportati possiamo notare un trend crescente delle fasce di prezzo sia nel comfort che nella componente di novità e sportività. Nello specifico:
La fascia economy presenta valori di novità e sportività molto bassi. Allo stesso modo anche per le componenti comfort e efficienza carburante i valori restano bassi.
La fascia regular, a differenza della prima, ha valori vicini allo zero per le tre componenti.
La fascia Premium assume valori di novità e sportività più o meno in linea con le regular, ma rispetto a quest'ultime ha valori inferiori. I valori di comfort invece sono di poco superiori sempre rispetto alle regular.
Infine, la fascia luxury ha valori di novità e sportività più elevati rispetto a tutte le altre classi. Per alcune auto il comfort è superiore alle altre categorie, tuttavia, alcune auto presentano valori di comfort in linea con tutte le altre fasce. L'efficienza del carburante invece mostra i valori più bassi tra le classi.
Di seguito sono riportate le medie delle singole componenti principali suddivise per le fasce di prezzo.

	Efficienza carburante	**Comfort**	**Novità e spotività**
Economy	-0,32217	-2,22738	-1,422195
Regular	1,285581	-0,5139088	-0,147546
Premium	0,01508059	0,4157177	-0,06545437
Luxury	-1,473708	0,2927338	0,5565594

Da una prima analisi si può affermare che le fasce di prezzo raccolgono varie categorie di auto. In particolare, la fascia luxury è composta sia da auto più sportive e quindi meno efficienti da un punto di vista del carburante, sia da auto più grandi, quindi con un livello di comfort più alto. La fascia economy, invece, racchiude auto usate e quindi per tutte le componenti avremo valori inferiori rispetto alle altre categorie.

REGRESSIONE STATISTICA

Dato lo scopo principale della ricerca, sono state effettuate delle regressioni per cercare di individuare la variazione del prezzo in relazione alle caratteristiche delle auto.
Per fare ciò sono state create delle variabili dummy al fine di rappresentare le caratteristiche delle auto più diffuse. Le variabili create sono:

- Suv 4dr → Assume valore 1 se l'auto è un Suv a 4 porte, 0 altrimenti;
- Sedan → Assume valore 1 se l'auto è una Sedan, 0 altrimenti;
- Coupé → Assume valore 1 se l'auto è una Coupé, 0 altrimenti;

- Luxury → Assume valore 1 se l'auto è di lusso, 0 altrimenti;
- Crossover → Assume valore 1 se l'auto è un crossover, 0 altrimenti;
- Performance → Assume valore 1 se l'auto è sportiva, 0 altrimenti;
- High.Performance → Assume valore 1 se l'auto ha alte prestazioni, 0 altrimenti;

- Automatic → Assume valore 1 se l'auto ha il cambio automatico, 0 altrimenti;

- Front_WDrive → Assume valore 1 se l'auto è a trazione anteriore, 0 altrimenti;
- Rear_WDrive → Assume valore 1 se l'auto è a trazione posteriore, 0 altrimenti;
- All_WDrive → Assume valore 1 se l'auto ha 4 ruote motrici, 0 altrimenti;

- Compact → Assume valore 1 se l'auto ha dimensioni compatte, 0 altrimenti;
- Large → Assume valore 1 se l'auto è di grandi dimensioni, 0 altrimenti.

Prima di effettuare le regressioni, i dati sono stati divisi in training (Train_Data) e test (Test_Data). Suddividendo il dataset originale all'80% per il training e al 20% per il test.

La prima regressione è quella lineare, la quale dà i seguenti risultati:

```
Coefficients:
                   Estimate Std. Error t value Pr(>|t|)
(Intercept)      -2.434e+06  1.829e+05 -13.312  < 2e-16 ***
Year              1.175e+03  9.163e+01  12.823  < 2e-16 ***
Engine.HP         1.915e+02  8.088e+00  23.674  < 2e-16 ***
Engine.Cylinders  9.703e+03  3.987e+02  24.340  < 2e-16 ***
Number.of.Doors  -5.002e+03  6.256e+02  -7.995 1.55e-15 ***
highway.MPG      -2.408e+02  1.718e+02  -1.401   0.1612
city.mpg          8.827e+02  1.336e+02   6.609 4.20e-11 ***
Popularity       -1.583e+00  2.397e-01  -6.605 4.33e-11 ***
Suv_4dr           4.696e+02  1.283e+03   0.366   0.7144
Sedan             8.818e+03  1.218e+03   7.239 5.10e-13 ***
Coupe            -3.036e+03  1.329e+03  -2.285   0.0223 *
Luxury            8.249e+03  8.142e+02  10.131  < 2e-16 ***
Crossover         7.015e+03  1.267e+03   5.535 3.25e-08 ***
Performance      -4.641e+03  9.448e+02  -4.912 9.28e-07 ***
High.Performance  1.224e+04  1.403e+03   8.725  < 2e-16 ***
Automatic        -2.336e+03  9.712e+02  -2.406   0.0162 *
Front_wdrive      9.146e+03  1.054e+03   8.681  < 2e-16 ***
All_wdrive        7.253e+03  9.192e+02   7.891 3.56e-15 ***
Compact           1.550e+04  9.621e+02  16.111  < 2e-16 ***
Large            -4.730e+03  9.740e+02  -4.857 1.22e-06 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 24840 on 5847 degrees of freedom
Multiple R-squared:  0.6611,    Adjusted R-squared:   0.66
F-statistic: 600.3 on 19 and 5847 DF,  p-value: < 2.2e-16
```

Come previsto dalla seconda e dalla 4 ipotesi, le variabili year, engine.Hp, e engine.cylinders hanno tutte coefficienti positivi e significativi.

Invece, per quanto riguarda la terza ipotesi, auto più grandi risultano avere un prezzo minore rispetto alle compatte. Ciò potrebbe essere spiegato dal fatto che auto più sportive, per avere elevate prestazioni, sono in generale più piccole al fine di ridurre la resistenza aerodinamica.

Lo scarto quadratico medio sul Test_Data è:
24505.09

Tuttavia, il test sulla normalità degli errori rifiuta l'ipotesi nulla.

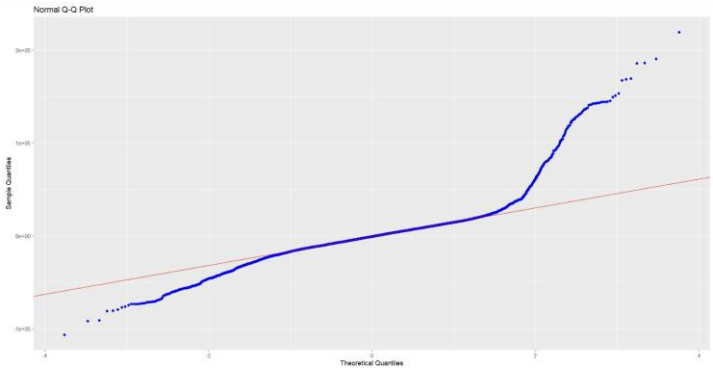

Ipotesi nulla che viene rifiutata anche verificando la presenza di omoschedasticità.

```
Non-constant Variance Score Test
Variance formula: ~ fitted.values
Chisquare = 7170.847, Df = 1, p = < 2.22e-16
```

Per tali ragioni, sono stati considerati altri modelli.

Abbiamo utilizzato il decision tree per effettuare una regressione su MSRP.
Come per gli altri modelli, il tree è stato allenato sul Train_Data e successivamente è stata valutata la bontà del modello sul Test_Data.
In particolare, per limitare la complessità dell'albero abbiamo impostato diversi limiti.
In primo luogo, è stato fissato un complexity parameter (CP) relativamente basso a 0.01.
Successivamente è stato imposto un vincolo alla profondità massima dell'albero pari a 5.
Infine, ogni nodo con meno di 20 osservazioni non potrà essere suddiviso.
L'albero ottenuto è il seguente:

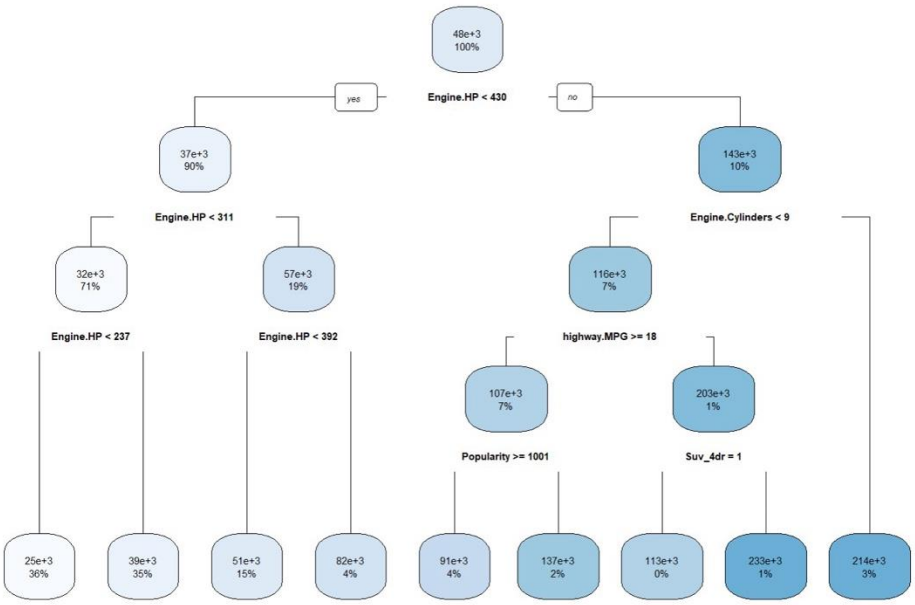

Come si può notare le variabili più significative sono Engine.HP, Engine.Cylinders, Highway.MPG e Popularity. Il valore del RMSE per il decision Tree è **20493.74**.

In seguito al decision tree è stato utilizzato il Random Forest. Anche in questo caso le variabili più rilevanti sono Engine.HP, Engine.Cylinders. Tuttavia, la terza e quarta variabile più importante sono High.Performance e City.MPG, il quale ha sostituito la variabile Highway.MPG.

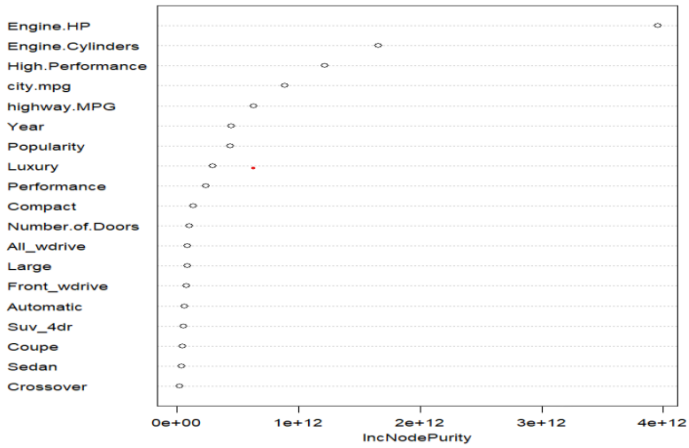

Grazie al seed impostato, il modello riesce a prevedere correttamente i valori di MSRP con uno scarto medio quadratico pari a **7055.03**

Ulteriore tecnica utilizzata per la previsione di MSRP è la rete neurale. La struttura della rete si compone di 3 strati nascosti: il primo con 2 neuroni, il secondo con un solo neurone, e l'ultimo con 3.

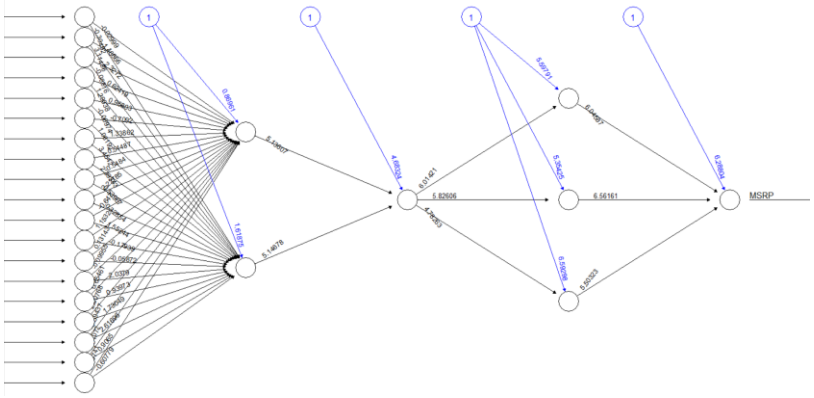

Nonostante i tre strati di hidden, l'algoritmo risulta essere il peggiore tra quelli utilizzati finora in quanto presenta un RMSE pari a **63362.58**

L'ultimo modello statistico utilizzato per la regressione del prezzo è il Support Vector Machine. Per perfezionare il modello è stato adottato il Cross-Validation con 10 folds. Inoltre, è stato utilizzato sia il kernel trick lineare sia quello non lineare, in particolare è stato usato il kernel Radiale (adottando così il Support Vector Regression SVR).

SVM con Kernel Lineare presenta un RMSE pari a 29094 ed un R-quadro pari a 0.6126. Il modello finale utilizzato per predire MSRP sul Test_Data ha invece un RMSE pari a **28940.41**. SVR è nettamente migliore almeno in termini di RMSE. Il modello presenta un RMSE pari a 14559.38 ed un R-quadro pari a 0.8890. Il modello finale utilizzato per predire MSRP sul Test_Data ha invece un RMSE pari a **14331.61**.

Riassumendo, il modello più affidabile è il Random Forest, ossia quello che presenta un RMSE minore:

Modello	RMSE	
Random Forest	7055,03	
SVM	14331,61	
Decision Tree	20493,74	
OLS	24505,09	*
Neural Network	63362,58	

* = nel caso della regressione lineare non sono rispettate le ipotesi per la sua applicazione

CLASSFICIAZIONE SULLE FASCE DI PREZZO

Dopo la regressione sul prezzo è stato affrontato l'aspetto della classificazione delle variabili nelle diverse fasce di prezzo precedentemente utilizzate nella PCA.
Come per la regressione, il dataset è stato suddiviso in training e test con le stesse proporzioni utilizzate precedentemente.

Il primo modello adottato è quello della regressione multinomiale. Come outcome response è stata scelta la prima fascia di prezzo, ossia economy. I coefficienti del modello sono i seguenti:

```
Coefficients:
  (Intercept)      Year  Engine.HP Engine.Cylinders Number.of.Doors highway.MPG   city.mpg   Popularity
2   -646.3795 0.3268321 0.01592462      -1.02306075       -1.299903 -0.08693396 0.01904412 3.506213e-05
3  -1106.4994 0.5524290 0.03744215      -0.85175783       -1.328923 -0.16243543 0.09254345 1.070247e-04
4  -1577.6385 0.7798297 0.05258840       0.03976591       -2.164276 -0.16092472 0.14265847 1.671904e-04
     Suv_4dr     Sedan     Coupe    Luxury Crossover Performance High.Performance Automatic Front_wdrive
2 0.4856506 0.9631623 -1.365249 -1.209224  82.84458  -0.3891965         147.3634  1.618196    0.4063854
3 0.2393053 0.8284750 -2.954623  2.839418  83.24502   0.0385465         149.9911  1.909019    0.3976176
4 2.4676022 1.9366398 -3.708519  6.432813  82.76354   0.3424986         150.0564  1.333740   -0.5604123
  All_wdrive    Compact     Large
2  0.2830741 -0.4310870 0.7142936
3  0.8868873 -1.0906538 0.6232019
4  1.2715172  0.4947657 2.1186094
```

Il modello si presenta come un buon classificatore delle fasce di prezzo con un'accuratezza sul Test_Data del **79.93%**. In particolare, questi sono gli errori di classificazione commessi dal modello.

prediction_multinom	1	2	3	4
1	45	7	4	0
2	18	344	66	2
3	4	66	501	73
4	0	0	54	281

Un altro modello adottato è l'analisi discriminante lineare (LDA). Una premessa importante riguarda il numero di osservazioni per le diverse classi. Queste, infatti, variano molto: la classe economy ha poche osservazioni mentre la classe luxury ne ha in abbondanza, portando così ad un data set sbilanciato e a probabilità a priori molto diverse fra le 4 classi. Nonostante questo, la LDA riesce a rappresentare mediante la prima funzione discriminante più del 75% della varianza.

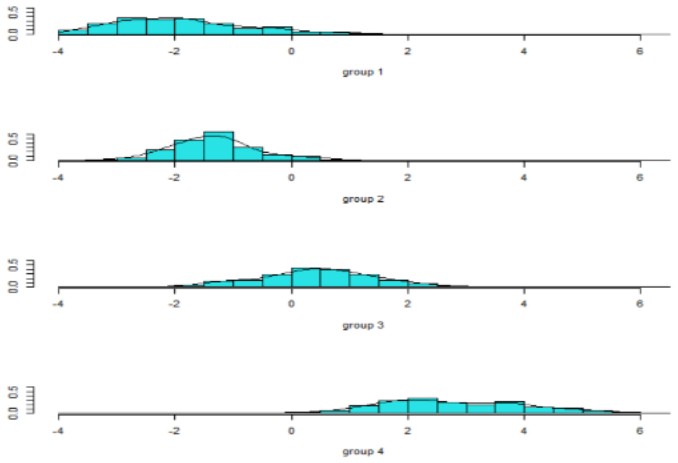

Dal grafico sopra è possibile vedere a quali valori dello score sono associate le fasce di prezzo. In particolare, tra -4 e -2 economy, tra -2 e 0 regular, tra 0 e 2 premium, tra 2 e 6 luxury.

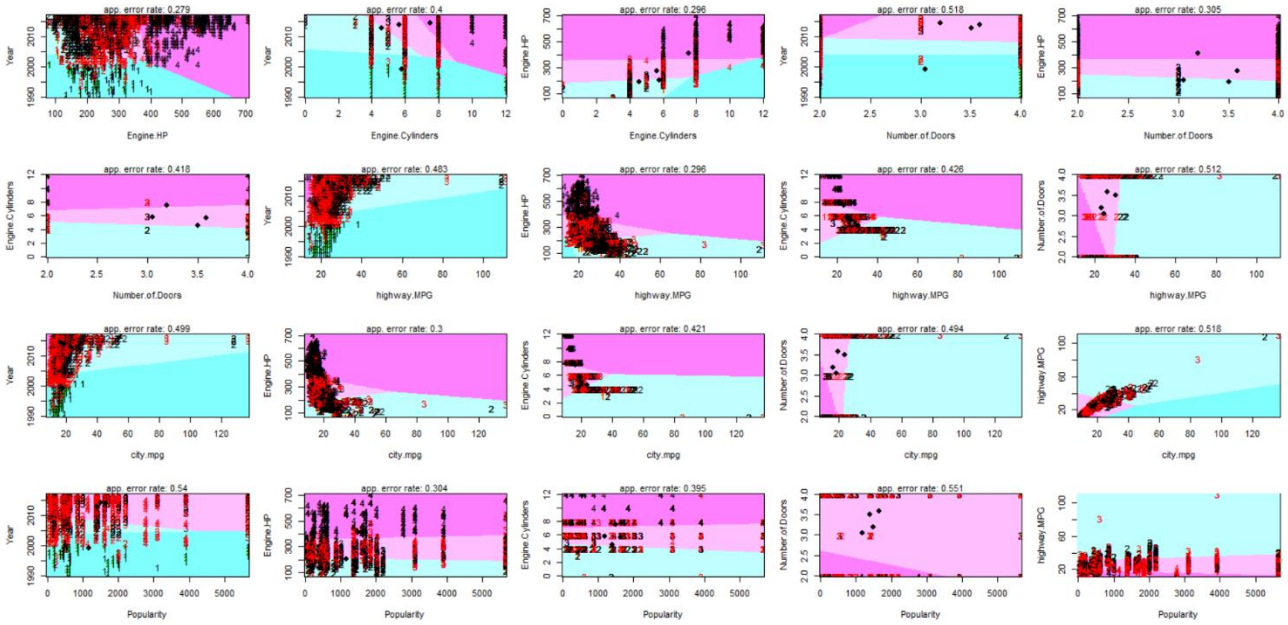

Ancora una volta, le variabili maggiormente discriminanti sono Engine.HP e Engine.Cylinders. La LDA ha una accuratezza del **78.03%** tuttavia bisogna evidenziare come tale modello non si possa adottare in quanto uno dei presupposti più importanti per poter utilizzare tale modello è la distribuzione normale delle variabili utilizzate. L'ipotesi nulla del test Marida (ossia che la distribuzione delle variabili sia MultiNormale) è rifiutata. A titolo di esempio si riportano i risultati per la prima fascia di prezzo; i risultati del test per le altre classi sono analoghi se non addirittura peggiori.

	Beta-hat	kappa	p-val
Skewness	16.15980	724.497894	0.000000e+00
Kurtosis	69.94829	5.076204	3.850502e-07

Come si può ben notare la distribuzione è molto asimmetrica con un valore Beta-hat diverso da 0 (spostata a destra) è la pesantezza delle code è molto elevata con un valore beta-hat della curtosi nettamente superiore a 3.

In seguito alla LDA sono stati nuovamente adottati i modelli di Decision Tree, Random Forest e SVM. Per il Decision Tree sono stati impostati gli stessi parametri per ridurre la complessità dell'albero utilizzati in precedenza. L'albero così ottenuto è il seguente:

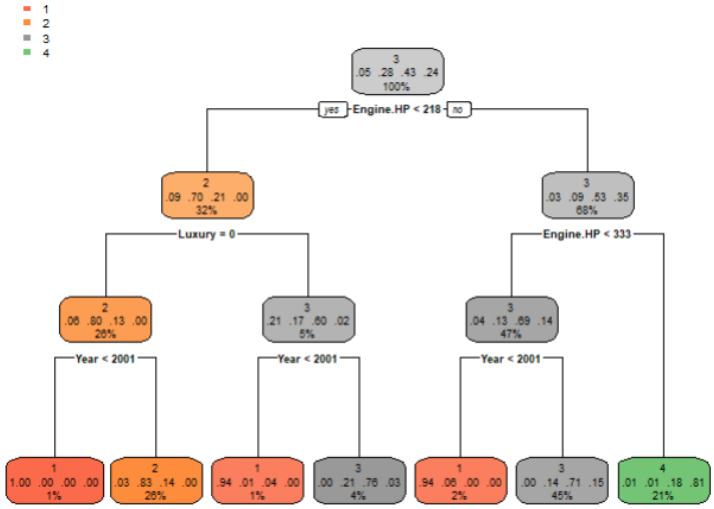

Si può notare come fra le variabili più importanti vi sia ancora Engine.HP. Tuttavia, si hanno anche nuove comparse come Luxury e Year. Nei nodi terminali uno in particolare emerge come "problematico" in quanto racchiude il 45% delle osservazioni, e di queste solo il 71% risultano correttamente classificate nella classe 3 (Premium). Ciò è visibile guardando alle previsioni del decision tree sul Train_Data.

```
  predict_unseen_zero
      1    2    3    4
1   209   50    0   10
2     7 1241  415    8
3     3  207 2072  221
4     0    2  400 1022
```

La precisione del Decision Tree nel classificare in base alle diverse fasce di prezzo è del **76.65%**.

Il modello Random Forest presenta un'accuratezza molto elevata pari al **88.73% e** significativamente diversa dalle percentuali ottenute precedentemente. Anche in questo caso le variabili più importanti nel random forest sono molto simili a quelle presenti nel decision tree:

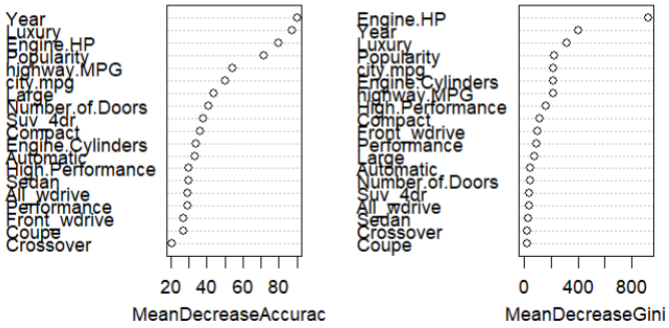

In seguito, è stato adottato il SVM. Tenendo in considerazione il fatto che le classi oggetto della nostra analisi sono 4, cioè superiori a 2 (il numero di classi tipicamente utilizzato nel svm), sono state adottate due diverse tecniche nel SVM. IL primo è il metodo one-to-one, il secondo è il one-to-rest.
Nel primo metodo ogni classe viene separata da una delle altre classi individualmente, cioè, separando la prima classe dalla seconda senza tenere in considerazione la terza e la quarta classe (e così via) con un totale di n*(n-1)/2 combinazioni. Nel nostro caso 6. Nel secondo caso viene scelta una classe e si individua l'iperpiano che meglio la separa rispetto a tutte le

altri classi considerate congiuntamente, in questo caso avremo 4 iperpiani. Anche in questo caso entrambi i modelli SVM adottano la Cross-Validation.
L'accuratezza per il modello one-to-one è del **80.20%** analoga è l'accuratezza del modello one-to-rest.

Infine, l'ultimo strumento utilizzato per la classificazione è il Nearest-Neighbour con cross-validation (KNN).

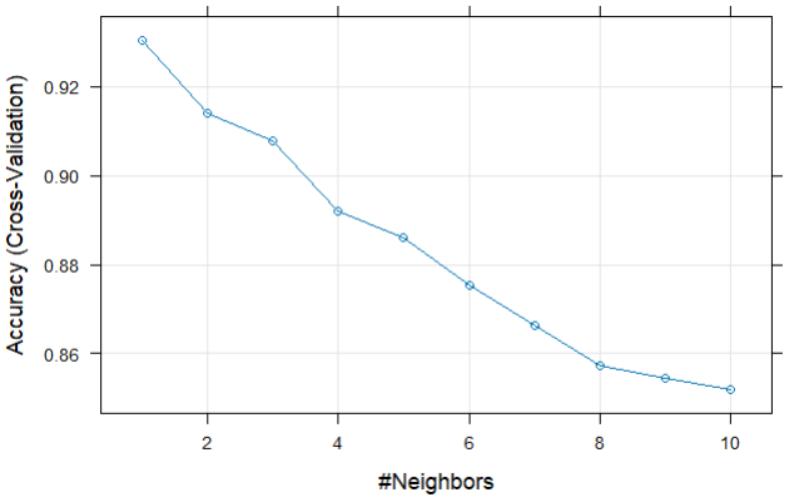

Come si evince dal grafico il modello scelto è il ONE-KNN dove l'accuratezza di classificazione raggiunge il **93.02%.** Malgrado l'elevatissima precisione nel ONE-NN, questa non permane nel Test_Data, scendendo ad una percentuale del 86.07. Ciò è probabilmente dovuto ad uno scaling issue oppure al fatto che i dati presentano una certa complessità ed il NN non interpreta i dati creando un modello ma si limita a memorizzare e classificare le osservazioni.

Riassumendo, il modello che meglio riesce ad assegnare una fascia di prezzo alle auto è ancora una volta il Random Forest, vista la maggiore precisione ottenuta nel Test_data:

Modello	Accuracy
Random Forest	88,73%
Knearest Neighbour	86,07%
SVM	80,20%
Reg. Multinomiale	79,93%
LDA	78,03% *
Decision Tree	76,65%

* = non è distribuita con una multi-normale

CLUSTER ANALYSIS

Una volta concluse tutte le regressioni su MSRP e le fasce di prezzo è necessario verificare se è possibile dividere le varie categorie di auto in più gruppi. In tale modo, è possibile verificare anche come il prestigio del marchio della casa automobilistica influenza fattori come prezzo e popolarità.

Al fine di effettuare l'analisi dei gruppi, ad alcune caratteristiche delle auto sono state associate dei valori numerici come di seguito:

Transmission.Type	
Manuale	1
Automatico	2
Semi-automatico	3

Driven.Wheels	
Trazione anteriore	1
Trazione posteriore	2
Trazione integrale	3

Vehicle.Size	
Compatta	1
Media	2
Grande	3

La prima tecnica di clustering adottata è quella gerarchica. In particolare, è stata utilizzata la distanza euclidea per il calcolo della matrice delle distanze e il metodo del legame completo. Il dendrogramma che ne risulta è il seguente:

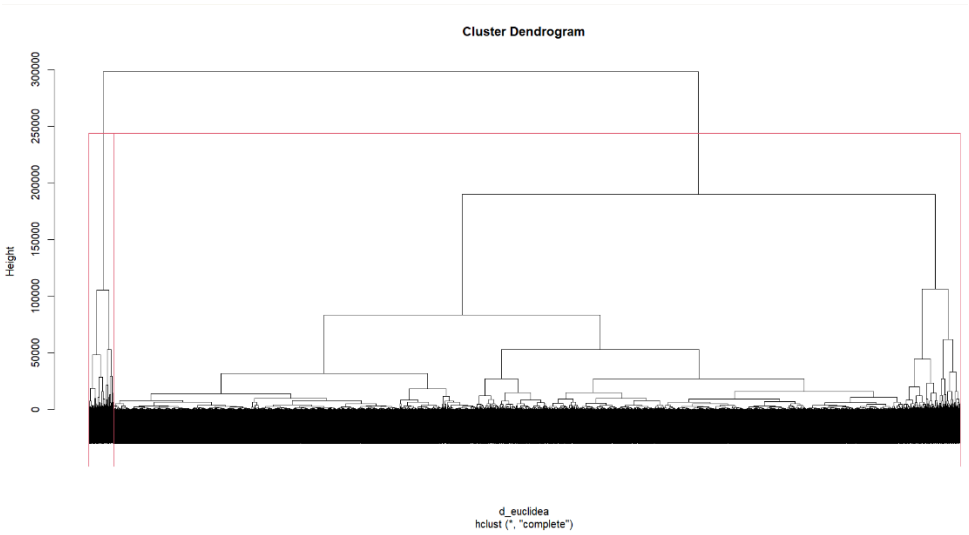

Il taglio dei gruppi è stato effettuato ad un'altezza pari a 20.000 dando origine a due gruppi distinti. I centroidi dei gruppi mostrano una netta differenza tra le caratteristiche delle auto.

Gruppo 1	
Year	2013
Engine.HP	271
Engine.Cylinders	6
Numbero.Of.Doors	4
Highway.MPG	26,85
City.MPG	19,8
Transmission.Type	2
Driven.Wheels	2
Vehicle.size	2
Popularity	1544
MSRP	42142

Gruppo 2	
Year	2012
Engine.HP	540
Engine.Cylinders	10
Numbero.Of.Doors	2
Highway.MPG	18,73
City.MPG	12,2
Transmission.Type	2
Driven.Wheels	2
Vehicle.size	2
Popularity	991
MSRP	235326

Nel gruppo 1 ci sono auto immatricolate più recentemente rispetto al gruppo 2. Inoltre, la potenza del motore è superiore nel secondo gruppo, dato il numero di cavalli e di cilindri mediamente maggiore. Ciò suggerisce che le auto del primo gruppo rientrano nelle categorie delle familiari, osservando il numero di porte maggiore, e delle auto per l'uso quotidiano. Nel secondo gruppo, invece, le auto possono essere considerate più sportive o ad alte prestazioni. Infatti, la potenza del motore è superiore a quella del primo gruppo e il numero di porte è uguale a due, suggerendo una tipologia di carrozzeria più sportiva.

Le variabili di interesse, MSRP e popularity, assumono valori differenti nei due gruppi. Nel gruppo 1 il prezzo è più basso ma con una popolarità maggiore. Ciò, può essere dovuto al fatto che auto familiari o utilitarie sono più diffuse rispetto ad auto sportive o ad alte prestazioni. Di conseguenza, le auto del gruppo 1 sono più citate in recensioni o pubblicità rispetto a quelle del gruppo 2. Dall'altro lato, le auto del gruppo 2 hanno un prezzo maggiore e un numero di interazioni a livello social minore data la minor diffusione e la maggiore esclusività.

Al fine di rappresentare il posizionamento dei vari marchi all'interno del mercato automobilistico, ogni singolo marchio è stato associato al gruppo a cui appartengono i propri modelli:

- Gruppo 1: BMW, Fiat, Chrysler, Nissan, Mazda, Merceds-Benz, Mitsubishi, Ferrari, Alfa Romeo, McLaren, Porsche, Volvo, Toyota, Sabb, Audi, GMC, Hyundai, Honda, Cadillac, Oldsmobile, Chevrolet, Dodge, Lincoln, Pontiac, Subaru, Volkswagen, Ford, Kia, Acura, Bentley, Maserati, Lexus, Aston Martin, Land Rover, Buick, Lotus, Infiniti, Scion, Genesi, Lamborghini, Suzuki, Plymouth, Hummer.

- Gruppo 2: Ferrari, McLaren, Porsche, Bentley, Spyker, Mercedes-Benz, Aston Martin, Lamborghini, Rolls Royce, Audi, Land Rover.

La ripetizione di alcuni marchi all'interno di ciascuno dei due gruppi è dovuta al fatto che alcuni coprono diversi segmenti di mercato. Ad esempio, Lamborghini offre sia auto ad alte prestazioni (Lamborghini Aventador) sia suv (Lamborghini Urus).

Un altro metodo per l'analisi dei gruppi è quello non gerarchico. In particolare, è stato adottato l'algoritmo K-mean.
La scelta del numero di gruppi adeguato è stata effettuata tramite la cosiddetta "tecnica del gomito". Il numero di gruppi per il quale inizia a diminuire la distanza intra-cluster è 2, così come visto con i metodi di clustering gerarchici.

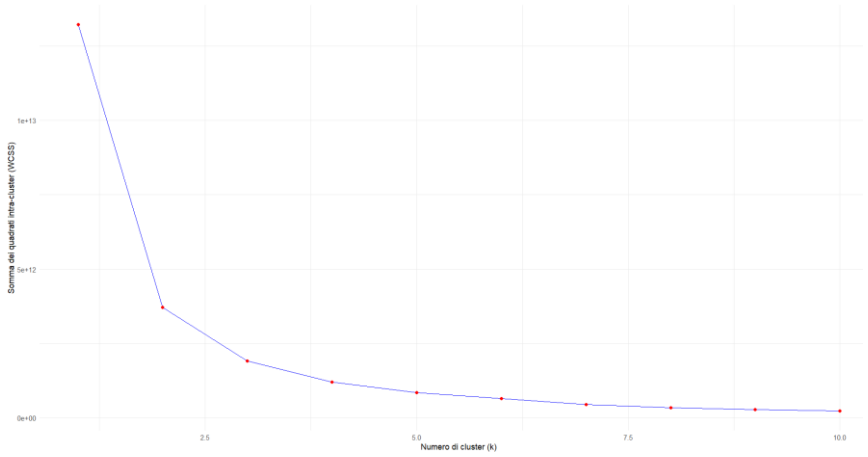

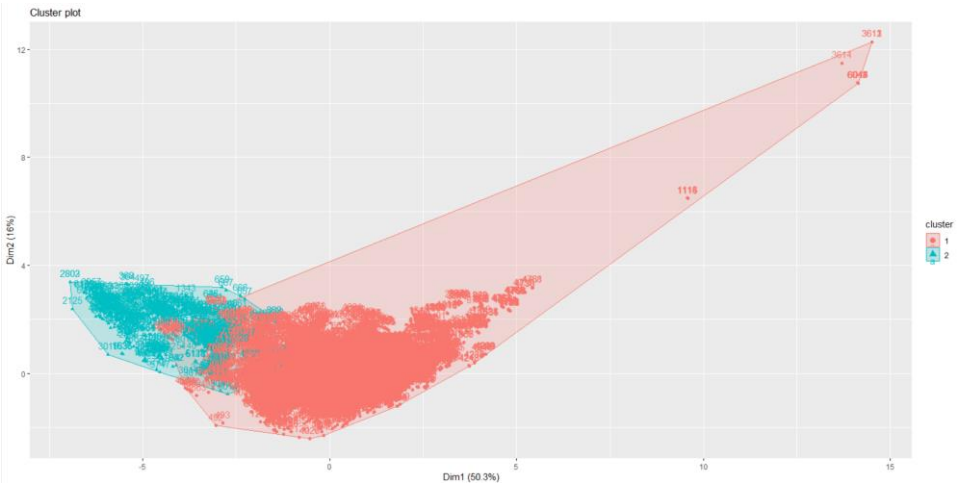

	cluster	Engine.HP	Engine.Cylinders	Number.of.Doors	highway.MPG	city.mpg	Popularity	MSRP
1	1	263.3197	5.566604	3.509681	27.0773	20.01878	1544.670	38298.4
2	2	513.7927	9.269978	2.518359	19.9568	13.15767	1283.138	186366.2

Nella figura, al fine di discriminare al meglio i due gruppi, sono state rimosse le variabili i cui valori medi nel gruppo erano pressoché identici. Tra le variabili rimosse ci sono: Year, Vehicle.Size, Transmission.Type e Driven.Wheels.
Come nel caso precedente, le auto possono essere distinte in familiari/utilitarie e sportive. Inoltre, i valori medi del gruppo combaciano con quelli precedentemente individuati nel clustering gerarchico.
Anche in questo caso viene confermata la relazione inversa tra Popularity e MSRP.

CONCLUSIONI

In seguito alle varie analisi condotte, sia in relazione al prezzo che con l'analisi dei gruppi, è possibile affermare che solo alcune delle ipotesi iniziali erano corrette.
Per quanto riguarda la prima ipotesi sostenuta, la potenza del motore è uno dei fattori maggiormente incisivi nel prezzo di un'auto. Infatti, il numero di cavalli e il numero di cilindri sono le state le variabili più importanti in tutti i modelli utilizzati.
La popolarità di un'auto, al contrario di come si potesse pensare, oltre ad avere un basso impatto sul prezzo, non è correlata positivamente con il prezzo. Infatti, auto con interazioni social maggiori risultano avere un prezzo minore rispetto ad auto meno citate.
Per quanto riguarda la dimensione dell'auto, invece, occorre fare una distinzione tra le varie categorie viste le differenze presentate tra i vari modelli utilizzati. Infatti, un'auto sportiva, e quindi più costosa, è generalmente di dimensioni minori rispetto ad un suv. Perciò, considerando le auto sportive, un aumento della dimensione ha un effetto negativo sul prezzo. Al contrario, considerando auto orientate al lusso e all'esperienza di guida, un aumento della dimensione concerne un aumento del prezzo.
Infine, è possibile affermare che auto più recenti, le quali godono dei sistemi di guida più moderni e delle ultime funzionalità, hanno un costo maggiore rispetto a quelle vendute in passato. In particolare, il prezzo risulta avere un notevole incremento a partire dal 2001.
Infine, occorre sottolineare che l'algoritmo migliore per assegnare il prezzo ad un'auto è il Random Forest, sia in termini di prezzo assoluto sia per le fasce di prezzo.