Regressione Binaria

Report. N.3

CREATO DA:

Lucia De Liberato
Marika Salvatori
Cecilia Fede
Ludovico Fonti
Jasmine Petrillo

Introduzione

I dati utilizzati provengono da un dataset relativo a una campagna di marketing telefonico di un'azienda specializzata in depositi a termine (investimenti a basso rischio con interessi monetari). Esso è composto da 41.188 osservazioni e 20 variabili.

L'obiettivo dell'analisi è identificare i profili dei clienti più propensi all'acquisto e individuare le caratteristiche che incidono maggiormente sulla decisione di accettare o rifiutare l'offerta commerciale.

Partendo dall'analisi esplorativa del dataset, sono state studiate le caratteristiche più rilevanti per la previsione degli acquisti, con particolare attenzione alla variabile target che indica la presenza o meno di un acquisto. Infine, è stato applicato un modello di regressione logistica per stimare la probabilità di acquisto dei clienti e fornire indicazioni strategiche per ottimizzare le future campagne di marketing.

Data Pre-processing

Durante la fase di pre-processing, è stata effettuata un'analisi preliminare per garantire la qualità del dataset.

In primo luogo, il dataset è stato standardizzato utilizzando la tecnica Min-Max[1] per normalizzare le variabili numeriche, garantendo che tutte le caratteristiche abbiano lo stesso intervallo di valori e migliorando l'efficacia e la stabilità del modello predittivo.

Proseguendo, è stata condotta un'indagine per individuare eventuali anomalie nei dati, poiché la presenza di valori estremi potrebbe influenzare negativamente le prestazioni del modello predittivo. A tal fine, è stato impiegato il metodo Isolation Forest, una tecnica avanzata di machine learning progettata per il rilevamento degli outlier, che sono poi stati eliminati per migliorare l'affidabilità e la precisione delle analisi successive.

Successivamente, è stata effettuata un'analisi per identificare le principali caratteristiche degli individui che hanno sottoscritto un deposito a termine. Durante questa fase, sono stati rilevati valori etichettati come 'unknown' in alcune variabili del dataset. Dopo un'attenta valutazione, si è deciso di mantenerli solo nei casi in cui rappresentassero informazioni significative per l'analisi e potessero offrire spunti utili per l'interpretazione dei risultati.

Le variabili categoriche sono state trasformate in formato numerico mediante encoding, includendo la conversione delle variabili ordinali e la creazione di variabili binarie (0 e 1) per quelle nominali. Inoltre, è stata creata la variabile 'age2'[2] per catturare eventuali relazioni non lineari con l'età.

---

[1] La standardizzazione Min-Max ridimensiona i dati tra 0 e 1, rendendoli comparabili senza alterarne la distribuzione. Si applica sottraendo il valore minimo della variabile e dividendo il risultato per il suo range (massimo - minimo).

[2] La variabile age2 rappresenta il valore dell'età elevato al quadrato (vedi paragrafo 'Insight sull'età')

Si è quindi proceduto all'analisi della correlazione tra le variabili numeriche nel dataset, per identificare variabili troppo correlate tra loro, che potrebbero causare problemi di multicollinearità, o variabili poco informative. In particolare, è stata utilizzata una matrice di correlazione per esplorare le relazioni tra le diverse variabili.

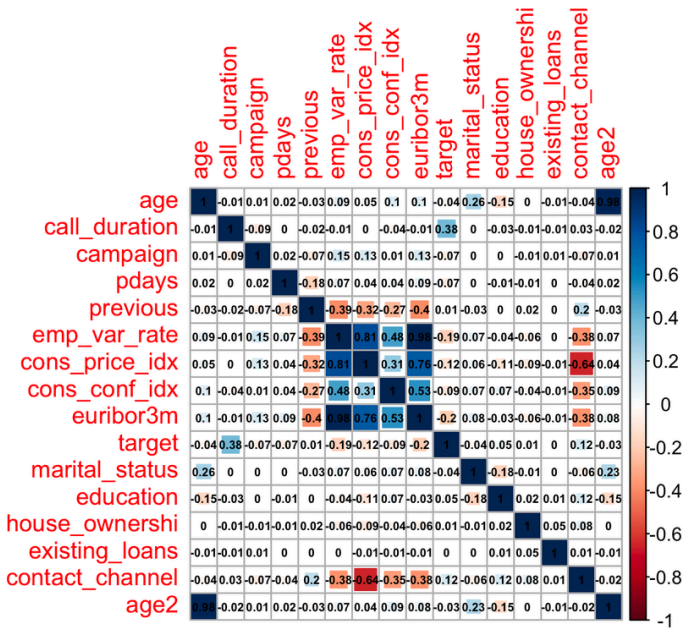

Matrice di correlazione dataset iniziale

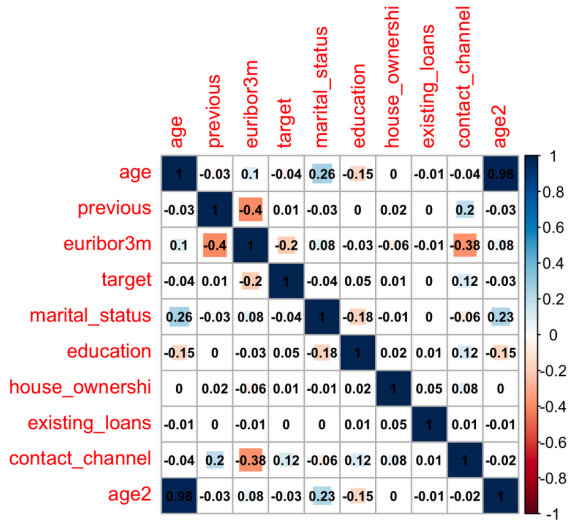

Matrice di correlazione del dataset pulito e ottimizzato

Nel passaggio dalla prima alla seconda matrice di correlazione sono state effettuate alcune scelte mirate per pulire e ottimizzare il dataset.

- Particolare attenzione è stata prestata alla variabile *Call duration*, che, pur non presentando una correlazione significativa con la variabile target, potrebbe comunque introdurre problemi di overfitting. Questo perché la durata della chiamata è un dato che può essere conosciuto solo al termine della chiamata stessa, rendendolo non utile per la previsione del comportamento del cliente durante il processo. Pertanto, è stata esclusa dal modello predittivo.
- Sono state inoltre identificate delle variabili con una correlazione significativa come *Cons Conf Idx*, *Cons Price Index* e *Emp Var Rate*. Queste variabili sono state rimosse per ridurre la complessità del modello e migliorare le sue performance, evitando multicollinearità.
- La variabile *Age2*, essendo una trasformazione di *Age*, è naturalmente fortemente correlata ad essa.
- Infine, è stata mantenuta una selezione di variabili ritenute più significative per la predizione del modello, e sono state eliminate le variabili meno informative o ridondanti, come *Record ID* e *Day of Week*.

L'analisi ha evidenziato un forte sbilanciamento della variabile target, con circa il 90% delle osservazioni pari a "0", rischiando di compromettere il modello predittivo. Per affrontare questa criticità, è stato applicato il metodo SMOTE[3], che ha permesso di generare nuove osservazioni sintetiche per riequilibrare le classi e migliorare la capacità del modello di riconoscere i casi positivi.

Infine, il dataset è stato suddiviso in training set (80%) e test set (20%) per la successiva fase di modellazione.

---

[3] *Nota tecnica: Per evitare problemi di overfitting, il bilanciamento delle classi non è stato impostato su un rapporto **50-50**, ma su un **60-40**. Questo approccio permette di migliorare la rappresentatività della classe minoritaria senza alterare eccessivamente la distribuzione originale dei dati, mantenendo il modello più robusto e realistico.*

Regressione Logistica

Nel presente studio, è stata utilizzata la regressione logistica[4] per esaminare i principali fattori che influenzano la propensione all'investimento, con l'obiettivo di ottimizzare le strategie di marketing per migliorare le performance della campagna.

Per ogni caratteristica dei possibili clienti abbiamo calcolato gli odds ratio, i quali indicano quanto quella caratteristica aumenta (se odds ratio maggiore di 1) o riduce (se odds ratio minore di 1) la probabilità di accettare l'offerta rispetto a chi non possiede quella caratteristica. Oltre agli odds ratio, sono stati stimati gli intervalli di confidenza al 95%, che indicano il grado di affidabilità delle stime. In particolare, se l'intervallo non contiene il valore 1, possiamo considerare il risultato statisticamente significativo.

	ODDS RATIO	INTERVALLO DI CONFIDENZA 95% MIN - MAX	SIGNIFICATIVITÀ
INTERCEPT	0.850	0.560 - 1.30	NULLA
AGE	3.72	1.46 - 9.52	MEDIA
AGE^2	0.0164	0.00370 - 0.0730	ALTA
JOB AMMINISTRATIVI	0.800	0.727 - 0.880	ALTA
JOB AUTONOMI	0.840	0.765 - 0.922	ALTA
CONTACT CHANNEL	2.56	2.40 - 2.72	ALTA
EDUCATION	1.06	1.04 - 1.08	ALTA
EURIBOR3M	0.118	0.109 - 0.128	ALTA
EXISTING LOANS	0.778	0.739 - 0.839	ALTA

	ODDS RATIO	INTERVALLO DI CONFIDENZA 95% MIN - MAX	SIGNIFICATIVITÀ
HOUSE OWNERSHIP	0.935	0.894 - 0.978	MEDIA
JOB MANUALI	0.87	0.826 - 0.916	ALTA
MARITAL STATUS	0.958	0.912 - 1.01	NULLA
P OUTCOME NON EXISTENT	1.57	1.06 - 2.29	BASSA
P OUTCOME SUCCESS	8.09	5.49 - 12.3	ALTA
PREVIOUS	0.015	0.001 - 0.189	MEDIA
SEASON AUTUMN	0.399	0.358 - 0.445	ALTA
SEASON SPRING	0.645	0.597 - 0.697	ALTA
SEASON SUMMER	1.04	0.953 - 1.13	NULLA

*La terza colonna è misurata con il p-value che indica il livello di significatività statistica dei risultati ottenuti dall'analisi.

Dall'analisi condotta emerge chiaramente che la storia del cliente rappresenta un fattore cruciale nella previsione della propensione all'acquisto. Tra le variabili più influenti spiccano *POutcome Success* e *Previous*, entrambe con un impatto significativo e diretto sulla probabilità di conversione.

Per quanto riguarda la variabile *Poutcome Success*, i clienti che hanno avuto un contatto positivo in passato mostrano una probabilità di acquisto nettamente superiore rispetto a coloro che non hanno avuto precedenti interazioni positive o che non sono mai stati contattati. In particolare, la probabilità di conversione aumenta di circa 8 volte quando il cliente ha avuto esito positivo in una precedente interazione.

[4] *Training del Modello: Il McFadden R^2 (0.1804) indica che il modello spiega il 18% della variabilità, mostrando una moderata capacità predittiva. L'AIC (47518.54) è stato utilizzato per confrontare modelli penalizzando la complessità. Il threshold ottimale per la classificazione è stato fissato a 0.4 per bilanciare sensibilità e specificità.*

Testing del Modello. Matrice di Confusione: L'accuratezza è del 70.53%, con sensibilità del 66.06% e specificità del 73.57%. Il Kappa (0.3932) indica una concordanza moderata. L'AUC (0.7634) suggerisce una buona capacità di separazione. La precisione è del 62.99%, il recall del 66.06% e l'F1-score di 0.6449, mostrando un buon equilibrio tra le metriche.

Di contro, la variabile *Previous* presenta un effetto fortemente negativo. I clienti contattati senza successo in passato vedono crollare la probabilità di conversione drasticamente, con un odds ratio di 0.015. Ciò conferma l'importanza di evitare di insistere su clienti già negativi, per non sprecare risorse e ottimizzare il ritorno sull'investimento.

Anche il contesto macroeconomico gioca un ruolo cruciale. La variabile *Euribor3m* ha un odds ratio molto basso (0.118), indicando che l'aumento dei tassi di interesse riduce drasticamente la propensione all'acquisto. L'alto valore dell'Euribor, infatti, indica che i finanziamenti diventano più costosi, quindi i consumatori sarebbero meno propensi a sottoscrivere nuovi prodotti finanziari o investire.

Anche il canale di contatto ha un ruolo importante nel successo della campagna. Nel dataset analizzato, il Cellular è stato il canale più utilizzato e si è rivelato il più efficace, con un impatto positivo significativo sulla risposta dei clienti. Con un odds ratio di 2.56, utilizzare il canale giusto raddoppia la probabilità di successo.

Le variabili socio-demografiche, come l'età e lo stato civile, hanno influenzato la propensione ad investire in depositi a termine, seppur in misura minore.

Per quanto riguarda l'età, questa risulta avere un comportamento particolare. La variabile *Age* ha un odds ratio di 3.72, indicando che con l'aumentare dell'età cresce anche la probabilità di adesione, anche se la significatività è media. Tuttavia, la presenza della variabile *Age2*, che risulta altamente significativa e con un odds ratio molto basso (0.0164), suggerisce che la relazione non è lineare: ci sono probabilmente delle fasce d'età centrali che rispondono meglio, mentre i troppo giovani o i troppo anziani sono meno convertibili.

Al contrario, il livello di istruzione mostra un effetto positivo significativo, seppur contenuto (OR 1.06): clienti con un livello di istruzione più elevato tendono a essere più informati e propensi a rispondere positivamente, percependo meglio il valore dell'offerta.

L'analisi delle variabili relative alla professione ha rivelato che tutte le categorie lavorative considerate, i lavoratori manuali, gli autonomi e gli impiegati amministrativi, mostrano odds ratio inferiori a 1 (0.87, 0.84 e 0.800 rispettivamente). Questo effetto è statisticamente significativo, confermando che il tipo di lavoro è un fattore socio-economico rilevante. Queste categorie professionali potrebbero essere meno interessate o più diffidenti rispetto alla proposta di acquisto, a causa di differenze nella disponibilità economica, nel rischio percepito o nell'interesse per il prodotto.

La situazione economica personale del cliente incide in modo evidente. Chi ha già prestiti esistenti è meno incline ad aderire a nuove proposte (OR 0.778), un dato che suggerisce di trattare questi clienti con cautela, proponendo eventualmente prodotti meno impegnativi. Anche il possesso della casa riduce leggermente la propensione all'acquisto (OR 0.935), anche se con una significatività solo media. I proprietari di casa potrebbero essere meno interessati ai depositi a termine perché spesso hanno meno liquidità a causa del mutuo o preferiscono investire nella propria abitazione. Inoltre, la loro maggiore sicurezza finanziaria potrebbe ridurre l'interesse per nuove offerte di investimento.

Interessante anche l'impatto della stagionalità. L'autunno si conferma come il periodo meno favorevole per le campagne, con un odds ratio di 0.399. Probabilmente perché è un periodo dell'anno in cui le persone sono più impegnate economicamente e mentalmente: rientro dalle ferie, spese scolastiche e magari già proiettate verso altre priorità. Anche la primavera mostra una leggera penalizzazione (OR 0.645), mentre l'estate sembra non avere un impatto particolare, sebbene vada monitorato, poiché i clienti potrebbero essere meno reperibili o più distratti dalle ferie.

Insight sull'età

Sull'età è stata condotta un'analisi approfondita[5], evidenziando una relazione non lineare con la probabilità di acquisto. È stato calcolato un punto ottimale, intorno ai 27 anni[6], in cui la probabilità di successo è massima, mentre oltre questa soglia tende a diminuire.

Il dataset è stato poi diviso tra giovani e adulti, con la costruzione di modelli separati per analizzare le differenze tra i due gruppi. I risultati mostrano comportamenti diversi: alcune variabili pesano di più sugli adulti, mentre i giovani risultano meno influenzati dalle esperienze pregresse o dai fattori stagionali.

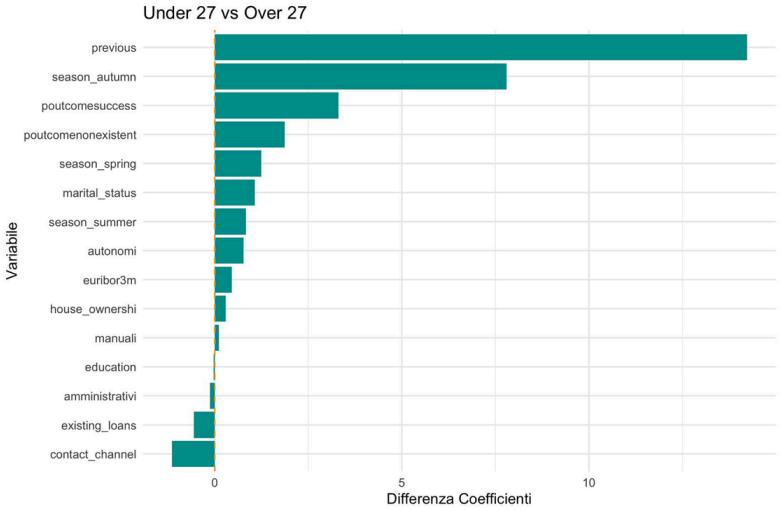

Il grafico confronta l'impatto delle variabili predittive tra due gruppi di età: giovani (Under 27) e adulti (Over 27). Ogni barra rappresenta la differenza nei coefficienti del modello tra i due gruppi. Valori positivi indicano che una variabile ha un effetto maggiore sugli adulti rispetto ai giovani, mentre valori negativi segnalano un'influenza più forte tra i giovani.

La variabile *Previous* incide maggiormente sugli adulti, distinguendo le due fasce d'età. Anche fattori legati alla stagionalità e alla storia del cliente influenzano di più gli over 27. Al contrario, variabili come *Contact channel* o *Existing loans* hanno un effetto minore o opposto tra giovani e adulti.

I clienti adulti risultano più sensibili alla relazione pregressa con la banca e alla stagionalità, probabilmente per la maggiore esperienza nella gestione di prodotti finanziari e l'attenzione alla credibilità dell'istituto. Al contrario, i giovani sembrano meno influenzati da questi fattori, forse per una minore familiarità con strumenti finanziari come il deposito a termine, che li rende più difficili da coinvolgere con queste leve.

L'età influisce sulla propensione all'acquisto e sulla risposta alla campagna, suggerendo la necessità di strategie di marketing differenziate per giovani e adulti, basate su leve decisionali specifiche per ciascun target.

---

[5] E' stata utilizzata l'ANOVA per testare l'impatto della variabile age², mostrando che migliora significativamente il modello (p-value = 0.000108). Ciò indica che la relazione tra età e probabilità di successo non è lineare, ma segue una curva. Il test di Chow ha analizzato differenze nei dati in base all'età, dividendo il campione in due gruppi intorno ai 27.53 anni. Il test ha prodotto una statistica F di 36.4832 con p-value 0, confermando un break strutturale. Questo suggerisce che la probabilità di successo varia significativamente tra le due fasce di età.

[6] L'analisi è stata completata con una "back transformation" per ottenere l'età ottimale nel suo valore originale, anziché nella forma standardizzata utilizzata nel modello. Questo ha prodotto un valore di età ottimale in termini concreti, che è stato calcolato e visualizzato.

Conclusione

Dall'analisi emerge che la relazione pregressa con la banca è il fattore più rilevante nel determinare la propensione all'adesione. Per questo motivo, è consigliato concentrare la campagna in primis sui clienti che hanno già risposto positivamente in passato (*Poutcome success*), perché rappresentano il segmento con la maggiore probabilità di conversione. Successivamente, si potrebbe puntare ai clienti mai contattati poiché si tratta di un segmento ancora "neutro", che potrebbe riservare buone opportunità di conversione se approcciato con la giusta offerta e modalità di contatto. Al contrario, insistere su clienti già contattati più volte (*Previous* elevato) o con altri prodotti finanziari attivi (*Existing loans*) rischia di ridurre l'efficacia della campagna e di generare percezioni negative; in questi casi, la strategia va ripensata, magari proponendo offerte diverse.

Un altro aspetto da non sottovalutare è il contesto macroeconomico. L'andamento dell'Euribor3m impatta in modo significativo, infatti i tassi d'interesse elevati rendono l'offerta meno interessante. È consigliabile quindi monitorare costantemente i tassi e sospendere o rimodulare la campagna nei momenti di maggiore sfavore economico, evitando di investire in contesti poco propensi alla sottoscrizione.

Una strategia efficace potrebbe quindi prevedere una fase dedicata ai clienti mai contattati, che rappresentano un target neutro ma potenzialmente ricettivo se approcciato con la giusta offerta e attraverso i canali più efficaci, come il cellulare, che raddoppia le probabilità di successo, risultando un'altra leva strategica fondamentale. Sarebbe quindi importante privilegiare i canali più performanti, riducendo l'uso di quelli che generano meno conversioni o che possono risultare più invasivi per i clienti.

È consigliabile adottare strategie diverse in base all'età dei clienti: i più giovani sono meno reattivi a logiche basate su esperienze passate o fattori stagionali, mentre i più adulti rispondono meglio a queste leve, per cui potrebbe risultare opportuno personalizzare la comunicazione, differenziando linguaggi e offerte.

Infine, la stagionalità influisce sulle performance: l'autunno si conferma il periodo meno favorevole per l'adesione, quindi è consigliabile evitare il lancio della campagna nei mesi autunnali o, se inevitabile, potenziare l'offerta e la comunicazione in quei periodi.

Queste linee guida potrebbero permettere un ottimizzazione della strategia di marketing, aumentando le probabilità di successo della campagna e migliorando l'efficienza degli investimenti.

Insights operativi:

- Clienti con Previous elevato: sarebbe preferibile un approccio meno invasivo, ad esempio inviando un report sui vantaggi del risparmio a lungo termine invece di proporre subito il deposito.
- Segmentazione per comportamento d'acquisto: per chi ha già rifiutato offerte simili in passato, si potrebbe proporre un incentivo per la prima sottoscrizione, rendendo l'offerta più allettante.
- Clienti con Existing loans: se il cliente avesse un mutuo a tasso variabile, potrebbe essere più utile offrire un prodotto di copertura dal rischio di aumento dei tassi d'interesse.