Cluster analysis sulle vendite

CREATO DA:

De Liberato Lucia
Fede Cecilia
Fonti Ludovico
Petrillo Jasmine
Salvatori Marika

Introduzione

Il progetto di analisi si sviluppa su un dataset di 2999 osservazioni e 18 variabili.

I dati sono stati raccolti dal 01-01-2018 al 28-04-2019.

L'obiettivo di questa analisi è identificare gruppi di clienti con caratteristiche simili attraverso un algoritmo di clustering. Questo permetterà di comprendere i loro comportamenti di acquisto e di sviluppare strategie di marketing mirate e più efficaci.

Pre processing

Il dataset fornito è stato sottoposto a una serie di operazioni di trasformazione e pulizia per garantire che fosse pronto per essere analizzato in modo accurato ed efficace.

Durante la revisione iniziale del dataset è stato osservato che alcune voci contenevano dati incoerenti. Un esempio evidente del problema si trova nelle prime 10 righe del dataset, dove è stato rilevato un caso in cui il prodotto aveva un valore lordo di 1648, ma è stato applicato uno sconto di -15656, ben superiore al prezzo del prodotto.

Day	Net.Quantity	Gross.Sales	Discounts	Returns	Net.Sales	Taxes	Total.Sales	Returned.Item.Quantity	Ordered.Item.Quantity
04/12/2018	2	2000	-2000	0	0	0	0	0	2
01/04/2019	2	1900	-1900	0	0	0	0	0	2
05/11/2018	0	1648	-15656	-824	0	0	0	-2	2
19/02/2019	1	1190	-1190	0	0	0	0	0	1

Per risolvere le incongruenze riscontrate nei dati, sono stati adottati i seguenti interventi:

1. Correzione dei valori di “Net Sales”: è stata verificata l'incoerenza tra “Gross Sales” e “Discounts”, e successivamente, la colonna “Net Sales” è stata corretta calcolando la differenza tra le due features;
2. Creazione della colonna “Total.Sales.Correct”: è stata aggiunta una nuova colonna, “Total.Sales.Correct”, calcolando la somma di “Net Sales” e “Taxes”, in modo da ottenere un valore corretto per ogni transazione;
3. Rimozione delle righe con valori errati: sono state rimosse le righe in cui “Net Sales” e “Return Item Quantity” erano entrambe pari a 0, in quanto non è possibile avere una vendita netta nulla senza resi nello stesso ordine.

Infine, è stata effettuata una standardizzazione dei dati numerici mediante Z-score standardization per portare tutte le variabili su una scala comune, al fine di evitare che alcune avessero un peso maggiore rispetto ad altre durante l'analisi.

Analisi della correlazione

Di seguito è stata presa in analisi la correlazione tra le variabili.

Nel contesto del clustering, variabili altamente correlate possono introdurre ridondanza e distorcere i risultati. Per visualizzare meglio queste relazioni, è possibile utilizzare una Matrice di correlazione.

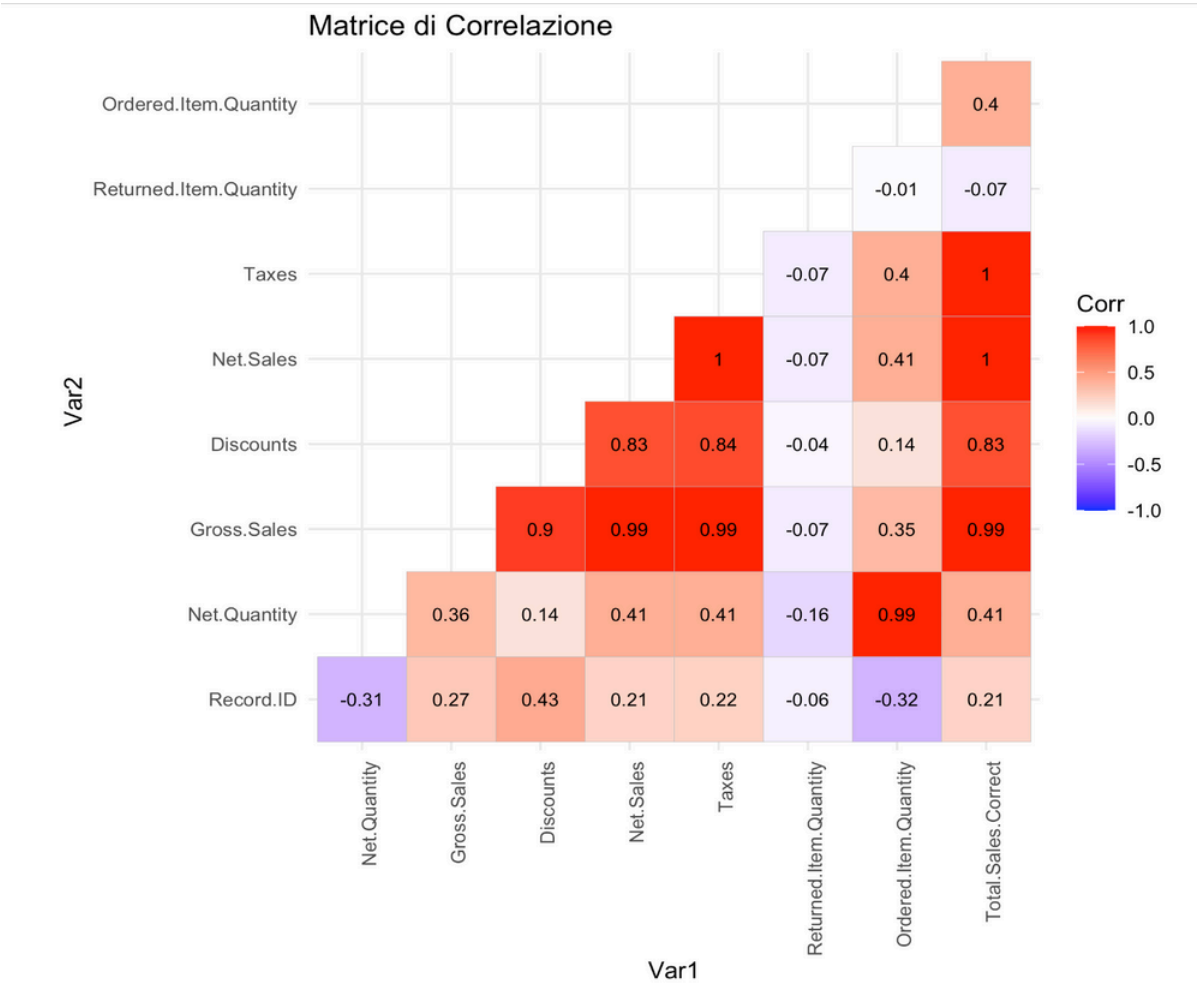

Nel nostro caso, il grafico mostra come alcune variabili siano altamente correlate.

Come è lecito aspettarsi infatti, le variabili derivate dalla somma di altre nel dataset risultano naturalmente correlate. Ad esempio, “Total.Sales.Correct” e “Taxes” sono fortemente legate, così come “Gross Sales” e “Net Sales” (0.99), indicando una relazione tra vendite lorde e nette, come anche “Net.Sales” risulta correlato con “Total.Sales.Correct”.

Inoltre, “Discounts” mostra una correlazione significativa con “Gross Sales” (0.90), come anche con Net.Sales (0.84), confermando l'impatto degli sconti sulle vendite. Infine, “Ordered Item Quantity” e “Net Quantity” (0.99) riflettono la relazione tra prodotti ordinati e venduti.

Sulla base di queste osservazioni, il clustering è stato eseguito utilizzando solo le variabili più rilevanti: “Net.Sales”, “Discounts”, “Returned.Item.Quantity”, “Ordered.Item.Quantity”.

Clustering

Per condurre l'analisi è stato selezionato il metodo PAM (Partitioning Around Medoids), un metodo molto efficace in presenza di variabili numeriche e valori anomali, basandoci sulla distanza di Manhattan[1]. Il numero ottimale di gruppi è stato determinato attraverso la combinazione della cosiddetta tecnica del gomito e l'indice di silhouette. Questo approccio ha permesso di individuare 3 cluster distinti. Questi corrispondono alla segmentazione dei clienti in base all'analisi delle loro vendite nette, gli sconti ricevuti, i resi[2] e la quantità di prodotti ordinati. Questa segmentazione ci aiuta a comprendere meglio i comportamenti di acquisto e a definire strategie mirate per ciascun gruppo.

Per fornire un'interpretazione sono state calcolate le metriche principali dei gruppi, in modo da fornire un'indicazione generale delle loro caratteristiche più rilevanti.

CLUSTER 1

CLIENTE A BASSA SPESA

Statistic	Net Sales	Discounts*	Ordered Item Quantity
Mean	875.78	-229.85	1.05
Min	0	-890	1
Max	1935	-215	2
Median	860	-215	1
Std. Dev.	179.89	63.67	0.22

Questo gruppo è composto da clienti che spendono relativamente poco, con una media di 875 per le vendite. Rispetto agli altri cluster risultano effettuare una spesa netta inferiore. Inoltre, ricevono pochissimi sconti (circa -229 in media) e tendono ad acquistare un solo prodotto alla volta.

CLUSTER 2

CLIENTE MEDIO

Statistic	Net Sales	Discounts*	Ordered Item Quantity
Mean	6117.11	-2104.75	1
Min	1966	-5951	1
Max	8667	-2084	1
Median	5833	-2084	1
Std Dev	803.9	217.56	0

I clienti di questo cluster generano vendite significativamente più alte rispetto al primo gruppo, con una media di 6.117 e un minimo di 1.966. Da sottolineare una presenza più rilevante di riduzione prezzi. Questi clienti acquistano sempre un solo prodotto per ordine, indipendentemente dallo sconto ricevuto.

CLUSTER 3

BIG SPENDER

Statistic	Net Sales	Discounts*	Ordered Item Quantity
Mean	12630.57	-2941.97	2.06
Min	1900	-4301	2
Max	29583	-475	4
Median	12667	-3167	2
Std Dev	3272	554.42	0.293

Questo cluster è composto dai clienti più redditizi, con una media di vendite che supera i 12.600 e un massimo che raggiunge 29.583. Sono quelli che ricevono i maggiori sconti (-2.941 in media) e, a differenza del Cluster 2, effettuano ordini più grandi, con una media di 2 prodotti alla volta, arrivando anche a 4 articoli per ordine.

[1] *Distanza di Manhattan: utilizzata perché tratta ogni dimensione in modo indipendente e riduce l'impatto di valori estremi.*

[2] *Resi: non sono poi stati presi in considerazione nelle metriche in quanto sono presenti in 4 osservazioni su 2900 considerate, quindi marginali.*

[3] *Discounts (in tabella): da considerare non in valore assoluto, ma il negativo indica la presenza dello sconto.*

Insights sui prodotti

Analizzando i prodotti più venduti per ciascun cluster, si è osservato che il Prodotto P risulta probabilmente il prodotto di punta, poiché ha la frequenza di acquisto più alta ed è principalmente acquistato dal Cluster 2, che rappresenta i clienti con acquisti più frequenti.

Al contrario, il Prodotto A è maggiormente acquistato dal cluster dei clienti a bassa spesa, che sono più sensibili al prezzo. Questo prodotto, infatti, potrebbe essere più economico o di livello entry-level.

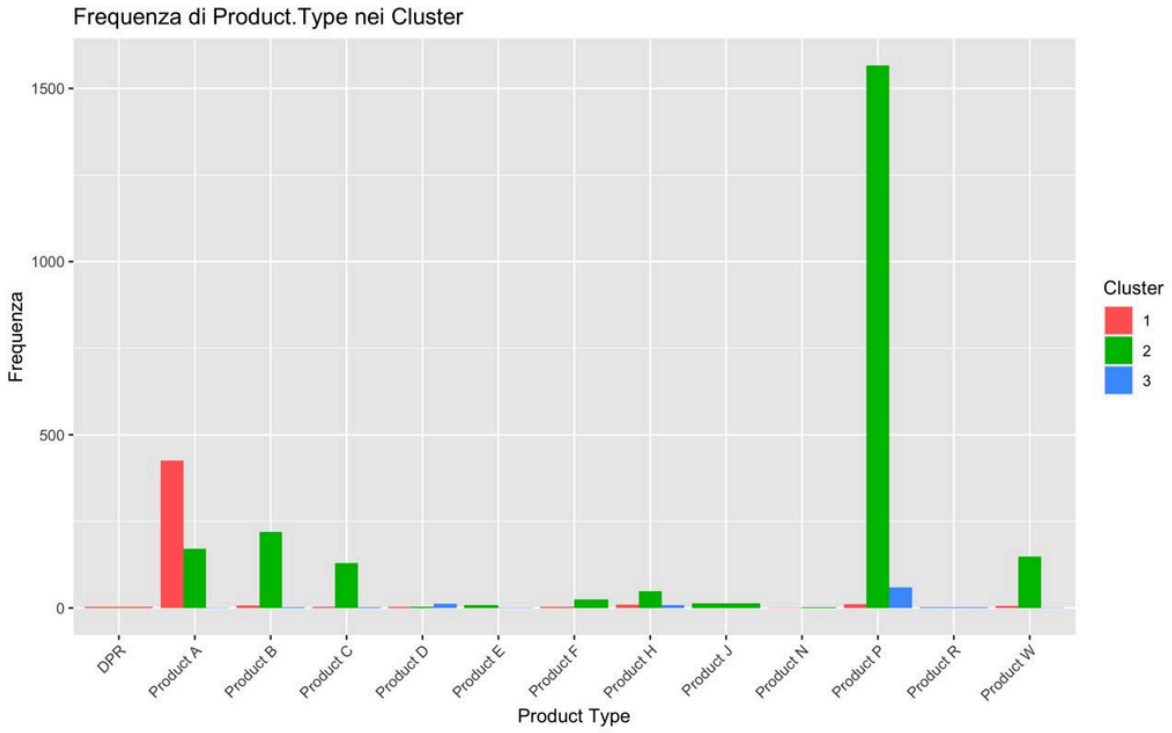

A differenza degli altri cluster, i Big Spenders sono probabilmente meno influenzati da prodotti di massa e più da servizi personalizzati, esperienze di acquisto premium e prodotti esclusivi. In questa logica sembra interessante osservare come il Prodotto R sia acquistato solo da segmento di clienti.

Il fatto che ordinano più prodotti sembra suggerire anche una volontà di investire in articoli che offrono un alto valore percepito, quindi prodotti di fascia alta o particolarmente ricercati.

Conclusioni

Dall’analisi dei dati di vendita e della segmentazione dei clienti, emergono tre profili distinti, ciascuno con comportamenti d’acquisto specifici. Per massimizzare la redditività e ottimizzare le strategie di marketing, è consigliabile adottare approcci mirati.

Il primo gruppo di clienti ha un valore economico ridotto. Si tratta di consumatori sensibili al prezzo, attratti da prodotti economici o entry-level. Per aumentarne la spesa media, è consigliabile proporre sconti progressivi o promozioni a tempo limitato al fine di creare un senso di urgenza. Queste strategie potrebbero incentivare acquisti più consistenti.

Il secondo gruppo è composto da clienti abituali, che effettuano acquisti frequenti, ma acquistano solo una singola unità per ordine. Per massimizzare il valore delle vendite, si potrebbero adottare due strategie: il cross-selling, che incentiva l’acquisto di prodotti aggiuntivi e complementari, e l’up-selling, che spinge verso prodotti di fascia più alta e con guadagni maggiori. Questo approccio permetterebbe di aumentare sia il numero di unità vendute che il valore netto di vendita per singolo acquisto.

Il terzo gruppo comprende un numero ristretto di clienti, ma con un impatto economico elevato. Si tratta di un segmento premium che sembrerebbe acquistare prodotti più costosi e quindi probabilmente più di nicchia. Per fidelizzarli e massimizzarne il valore, potrebbe essere utile offrire esperienze esclusive, edizioni limitate e servizi personalizzati, facendo attenzione a non compromettere o stravolgere l’esperienza d'acquisto.

Infine, monitorare periodicamente l’evoluzione di ciascun cluster e testare nuove strategie potrebbe permettere di adeguare le decisioni strategiche nel tempo, per garantire una crescita sostenibile e un’esperienza d’acquisto più efficace per i clienti.